単一GPU上のSTG実行

CUDA Stream配置とSM資源配分

実カーネルの依存関係・代表処理時間・SMプロファイルを用いた二段階ヒューリスティック

評価対象
合成STG / KESCO由来アプリケーション6種類

主張：GPU makespanでは、Stream並列性の効果と非均等SM配分の限界を分けて評価する必要がある。

1. 背景

GPUアプリケーションは、複数のCUDAカーネルを依存関係付きで実行する。

- 独立したタスクは複数Streamで並列実行できる
- 後続タスクは先行タスクの完了を待つ
- 複数Streamは同じGPUのSMを共有する
- カーネルごとにSM数への性能特性が異なる

```
実行時間
  = DAGの並列性
  + クリティカルパス
  + SM競合
  + タスク投入・同期・Green Contextのコスト
```

2. 研究目的

検証する問い

1. 複数Streamによるタスク並列性は有効か
2. bottom levelによる重要度付けは追加効果を持つか
3. 実測SMプロファイルによる資源配分は有効か
4. DAG構造によって効果が変わる理由は何か

仮説

独立分岐が多いDAGではStream配置の効果が現れやすい。
一方、長い分岐が合流するDAGでは、遅い分岐と合流待ちが性能を支配する。

3. 用語：タスクとカーネル

タスク

スケジューラが順序と実行先を決める処理単位。
本研究では、1タスクが1つのCUDAカーネル、または1回のカーネル起動に対応する。

CUDAカーネル

GPU上の多数のスレッドで実行される関数。
例：`conv2d`、`gaussian_blur`、`sobel`、`concat`。

`proc_time`

各タスクの代表処理時間。STGの重みとして、重要度計算と初期配置に利用する。

4. 用語：STG・DAG・依存関係

DAG（Directed Acyclic Graph）

有向辺を持ち、循環しないグラフ。ノードはタスク、矢印は先行完了を要求する制約を表す。

STG（Static Task Graph）

実行前にタスクと依存関係を固定した静的タスクグラフ。
本研究ではtask ID、`proc_time`、先行タスクIDを入力として使用する。

readyタスク

すべての先行タスクが完了し、実行可能になったタスク。

重要：依存関係を守ることが、正しい並列実行の前提である。

5. 用語：Stream・SM・Green Context

CUDA Stream

GPUへ投入する処理の順序を管理する実行列。異なるStreamは条件が整えば同時実行される。

SM（Streaming Multiprocessor）

CUDAカーネルを実行するGPU内の計算資源。複数Streamは同じSMを共有する。

Green Context

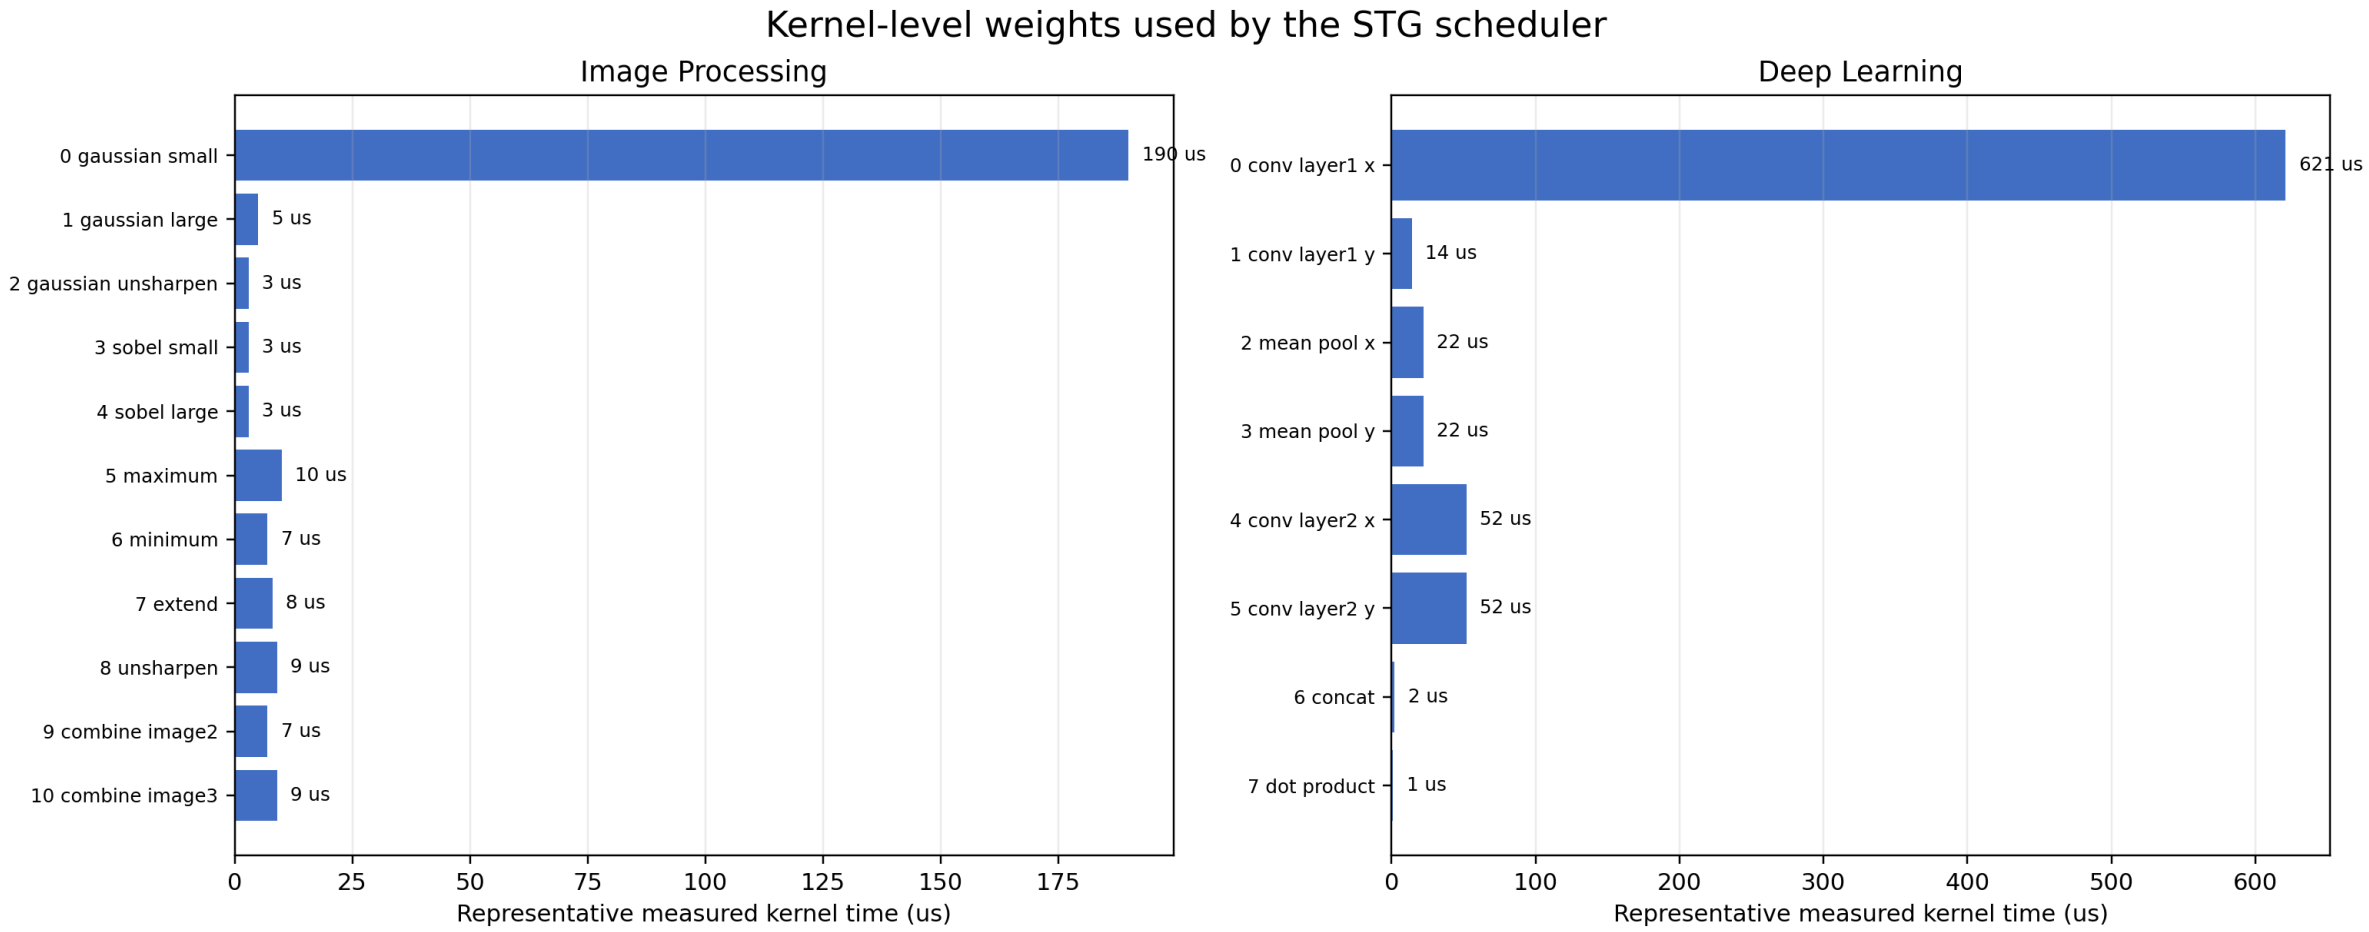
実行単位が利用できるGPU資源を制限する仕組み。本研究では比較対象として扱う。

6. 実カーネルからSTGへ

```
CUDA実装の確認
      ↓
task IDとカーネルの対応付け
      ↓
入出力バッファから依存関係を定義
      ↓
実カーネルを測定して proc_time を決定
      ↓
8〜64 SMでSM依存時間を測定
      ↓
STGを入力として実GPUで検証
```

> STGは実行トレースから自動抽出したものではない。
> 実装上のタスク対応、データ依存関係、測定値を静的入力へ整理したものである。

7. STGと実カーネルの対応



8. 図7の読み方

- STGのtask IDは、ランチャ・SMプロファイル・検証処理で共通
- `proc_time` は実カーネルの代表測定時間
- カーネル名はCUDAランチャ側のtask ID対応で管理
- 最終性能はSTG上の予測値ではなく、実GPU実行時間で評価

9. 提案手法の全体像

提案手法は、**Stream配置**と**SM配分**を分けて決定する。

```
入力：STG、proc_time、実カーネルのSMプロファイル
  ↓
Stage 1：依存関係・level・後続関係を構築
  ↓
Stage 2：bottom levelでreadyタスクを優先順位付け
  ↓
Stage 3：Stream配置を固定し、SM配分を探索
  ↓
出力：各タスクのStreamと各StreamのSM数
```

配置を先に決めることで、Stream配置とSM配分の探索を分離する。

10. Stage 1：STG解析

各タスクについて次を構築する。

- 先行タスク集合 `P_i`
- 後続タスク集合 `S_i`
- 未完了先行数 `indegree`
- トポロジカルな `level`
- `proc_time` に基づくタスク重み

実行前に以下を検出する。

- 未知の先行タスクID
- 重複したタスクID
- 負の値や不正な入力
- level化できない循環依存

目的：
不正なDAGをGPU実行前に排除し、後段の配置処理へ正しい依存関係を渡す。

11. Stage 2：タスク重要度

タスク `i` のbottom levelを、後続経路の長さとして定義する。

```
b_i = p_i                              if S_i is empty
      p_i + max(b_j for j in S_i)      otherwise
```

- `p_i`：タスク `i` の代表処理時間
- `S_i`：タスク `i` の後続タスク集合
- `b_i`：タスク `i` から末端までの推定残り時間

ready状態のタスクから、次の順で選択する。

1. `b_i` が大きいタスク
2. `proc_time` が大きいタスク
3. task IDが小さいタスク

12. Stage 3：Stream配置

タスク `i` をStream `s` へ置く候補を評価する。

```
r_i = max(f_j for j in P_i)
f(i, s) = e(i, s) + p_i
```

- `r_i`：先行タスク完了後のready時刻
- `e(i, s)`：Stream `s` の既配置区間を考慮した開始時刻
- `f(i, s)`：配置候補の終了時刻

各readyタスクを、**予測終了時刻が最小となるStream**へ配置する。

この段階では、まだSM配分を変更しない。

13. Stage 4：実測SMモデル

各実カーネルを、固定条件でSM数別に測定する。

```
SM数：8, 16, 24, 32, 40, 48, 56, 64

g_i(x) = task i の x SMにおける測定時間
p_hat_i(x) = g_i(x)
```

- 測定点の間は線形補間
- 64 SMを超える候補は64 SMの値で飽和
- タスクごとに異なるSM依存性を保持

したがって、SM配分は一様な「タスク数分割」ではなく、実カーネルの測定値に基づく。ただし、測定値に基づく非均等配分が、均等配分を常に上回るわけではない。

14. SM配分の目的

Stream配置 `sigma` を固定し、Stream `s` の予測負荷を計算する。

```
L_s(x, sigma)
  = sum(p_hat_i(x_s) for tasks i with sigma(i) = s)

C_hat(x, sigma)
  = max over streams s of L_s(x, sigma)
```

SM配分候補 `x` は、`C_hat` が小さくなるように選ぶ。

ただし、`C_hat` は次を完全には表現しない。

- 依存関係による待ち時間
- 同時実行時の性能変化
- カーネル投入・同期コスト
- Green Contextの生成・解放コスト

最終評価には、実GPUの `gpu_kernel_ms` を用いる。

今回の検証上の位置付け：
SM配分は有効性を検証する候補機構であり、導入自体を正当化する前提ではない。

15. 構造指標と解釈

```
T >= max(W / M, CP)
```

- `W`：タスク処理量の総和
- `M`：利用可能なSM数
- `CP`：クリティカルパス長

これは、処理量がSM数に比例して分散できると仮定した**理想化モデル**である。

実カーネルでは性能が非線形に変化するため、厳密なGPU時間の下界ではない。
Stream追加の効果や、DAGに含まれる並列化余地を説明する構造指標として用いる。

16. 実験設計

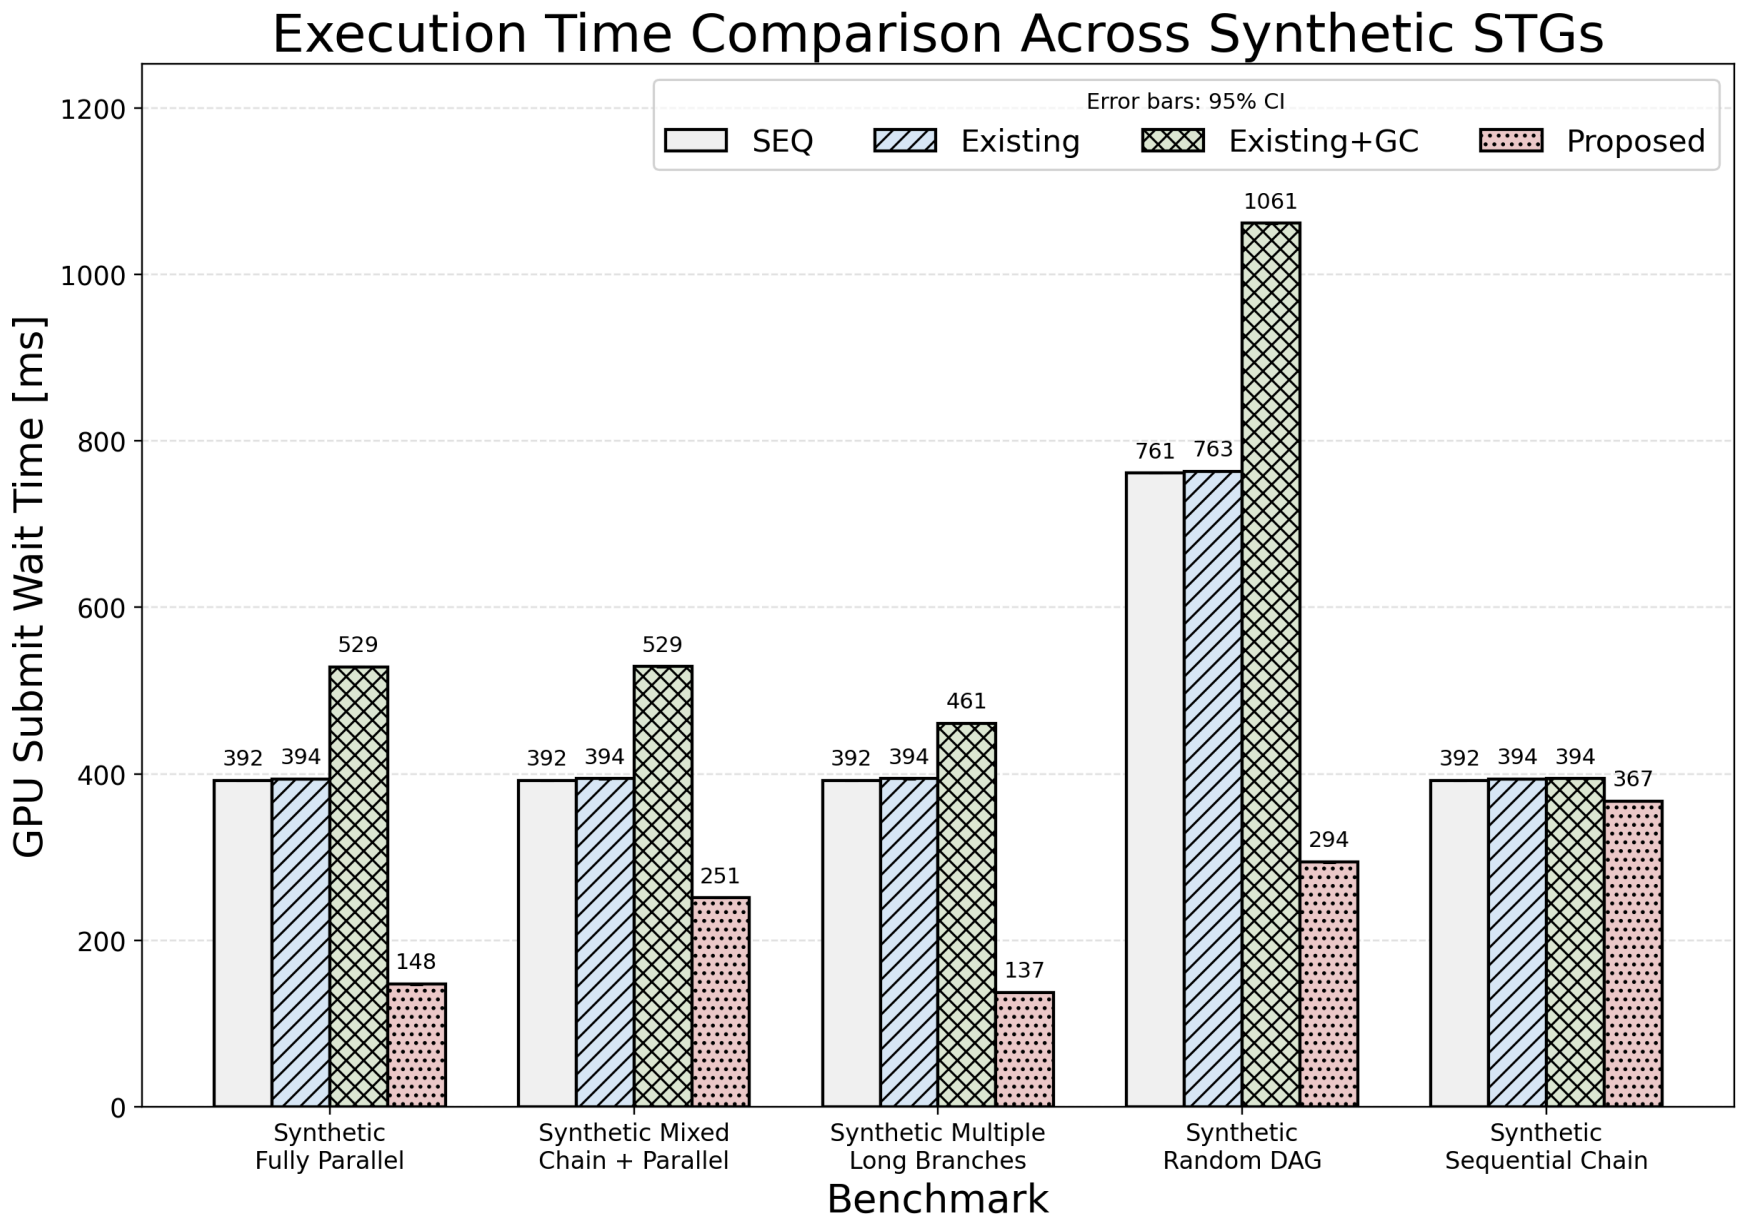
比較方式

方式	内容
Sequential	依存順に逐次実行
Existing	既存のStream配置
Existing + GC	既存配置 + Green Context
Proposed	重要度配置 + 実測SM配分

測定条件

- 合成STG：5種類
- KESCO由来アプリ：6種類
- 各条件33回
- 最初の3回をウォームアップとして除外
- 残り30回の平均、標準偏差、中央値、95% CI
- 実アプリ22/24条件で数値検証PASS（HITSのExisting/ProposedはFAIL）

17. 合成STG：実行時間



18. 合成STGの読み方

観察結果：

- 5種類すべてでProposedが最短
- Fully ParallelでもProposedが147.55 msで最短
- Existing + GCは全グラフで最長またはそれに近い

解釈：
合成STGでは、今回の入力・GPU・実装条件においてProposedが有効だった。ただし、実アプリケーションでは同じ傾向が再現していないため、合成STGだけで一般性を主張しない。

19. 合成STG：全結果

グラフ	Sequential	Existing	Existing + GC	Proposed
Fully Parallel	392.29	394.12	528.62	**147.55**
Mixed Chain + Parallel	392.33	394.27	528.85	**251.30**
Multiple Long Branches	392.27	394.24	461.02	**137.47**
Random DAG	761.23	763.33	1061.25	**294.04**
Sequential Chain	392.30	394.06	394.44	**367.33**

単位：ms。各値は平均実行時間。

赤字：各グラフで最短の方式。

20. 実アプリケーション：4方式比較



21. 実アプリケーションの読み方

主な結果：

ベンチマーク	最短方式	時間
image_processing	Proposed	64.32 ms
deep_learning	Existing	128.58 ms
black_scholes	Existing	1.83 ms
hits	除外（検証FAIL）	—

重要な点：
提案方式は、6アプリケーションすべてで最短ではない。

22. 実アプリケーション：全結果（gpu_kernel_ms）

ベンチマーク	Sequential	Existing	Existing + GC	Proposed
vector_square	100.63	**68.67**	68.69	68.70
black_scholes	2.77	**1.83**	2.39	2.18
machine_learning	**460.50**	461.37	475.77	460.65
hits	317.48*	291.93*	294.28	167.57*
image_processing	77.88	71.11	72.58	**64.32**
deep_learning	233.17	**128.58**	133.79	131.24

単位：ms。各値は平均実行時間。

赤字：数値検証PASSした条件で最短の方式。*：HITSは数値検証FAILのため、全方式の値を参考値として性能比較に使用しない。

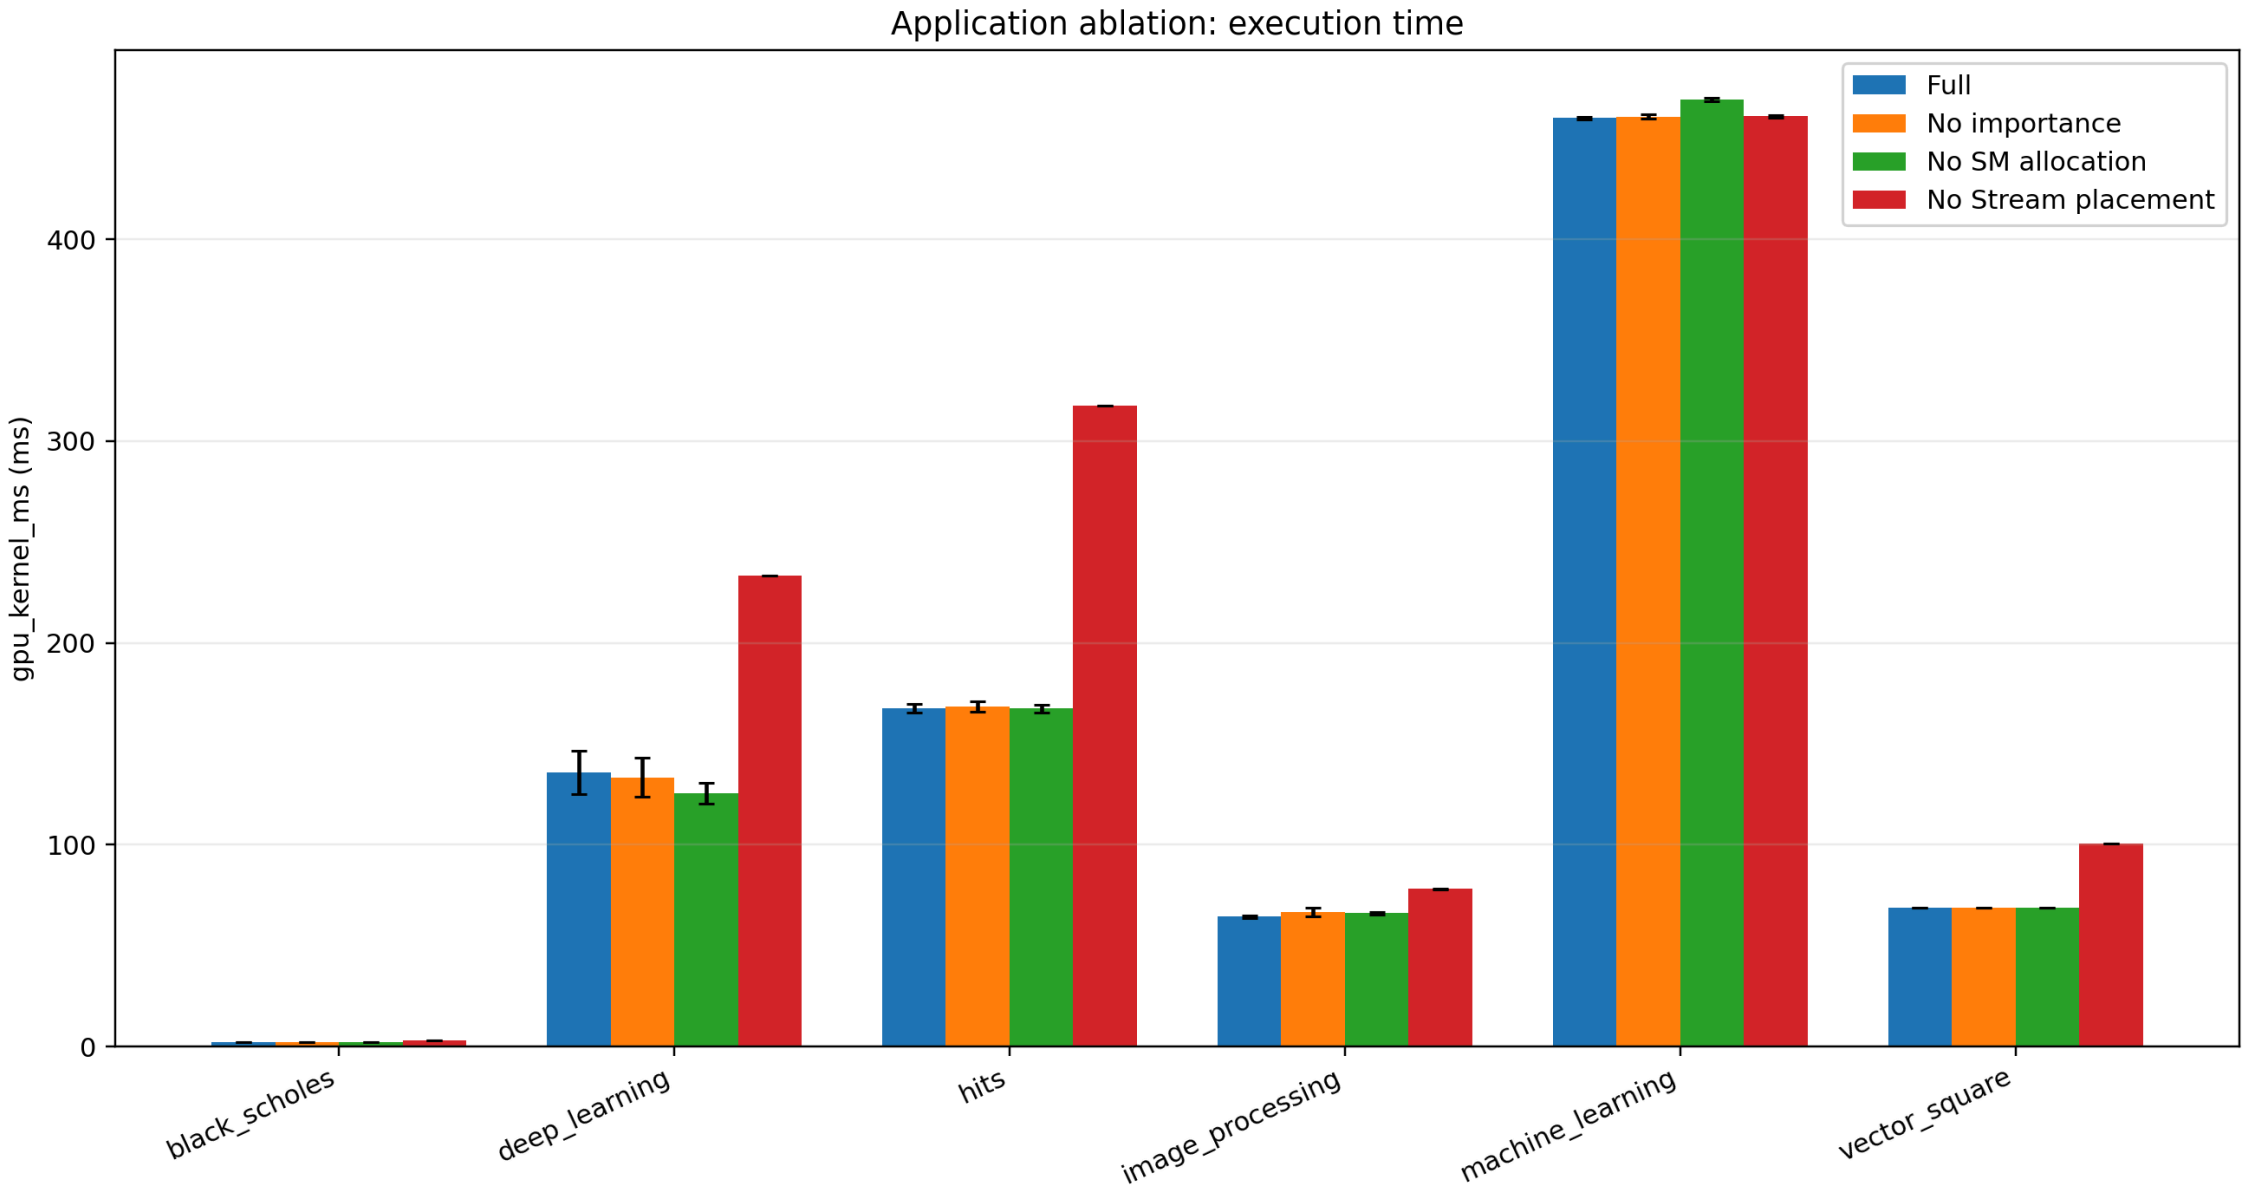
23. 厳密アブレーションの設計

提案パイプラインを固定し、一つの要素だけを無効化する設計である。正式なGPU makespan結果は再測定後に確定する。

条件	無効化する要素
`Full`	重要度・Stream配置・SM配分を使用
`No importance`	bottom levelによる優先順位
`No SM allocation`	非均等なSM配分
`No Stream placement`	複数Stream配置

この比較により、4方式比較では分離できない個別要素の寄与を確認する。

24. 厳密アブレーション：結果



25. アブレーションの数値

GPU makespan再測定結果

最初のタスク開始から最後のタスク終了までをCUDA Eventで測定した`gpu_kernel_ms`の平均値である。

26. アブレーション：全アプリ結果

ベンチマーク	Full	No importance	No SM allocation	No Stream placement
vector_square	68.74	68.73	**68.71**	100.75
black_scholes	**2.16**	2.22	2.18	2.90
machine_learning	**460.14**	460.87	469.34	461.00
hits	**167.48**	168.32	167.50	317.62
image_processing	**64.36**	66.60	66.18	78.04
deep_learning	135.94	133.36	**125.62**	233.39

単位：ms。各値は平均実行時間。

赤字：各アプリケーションで最短のアブレーション条件。

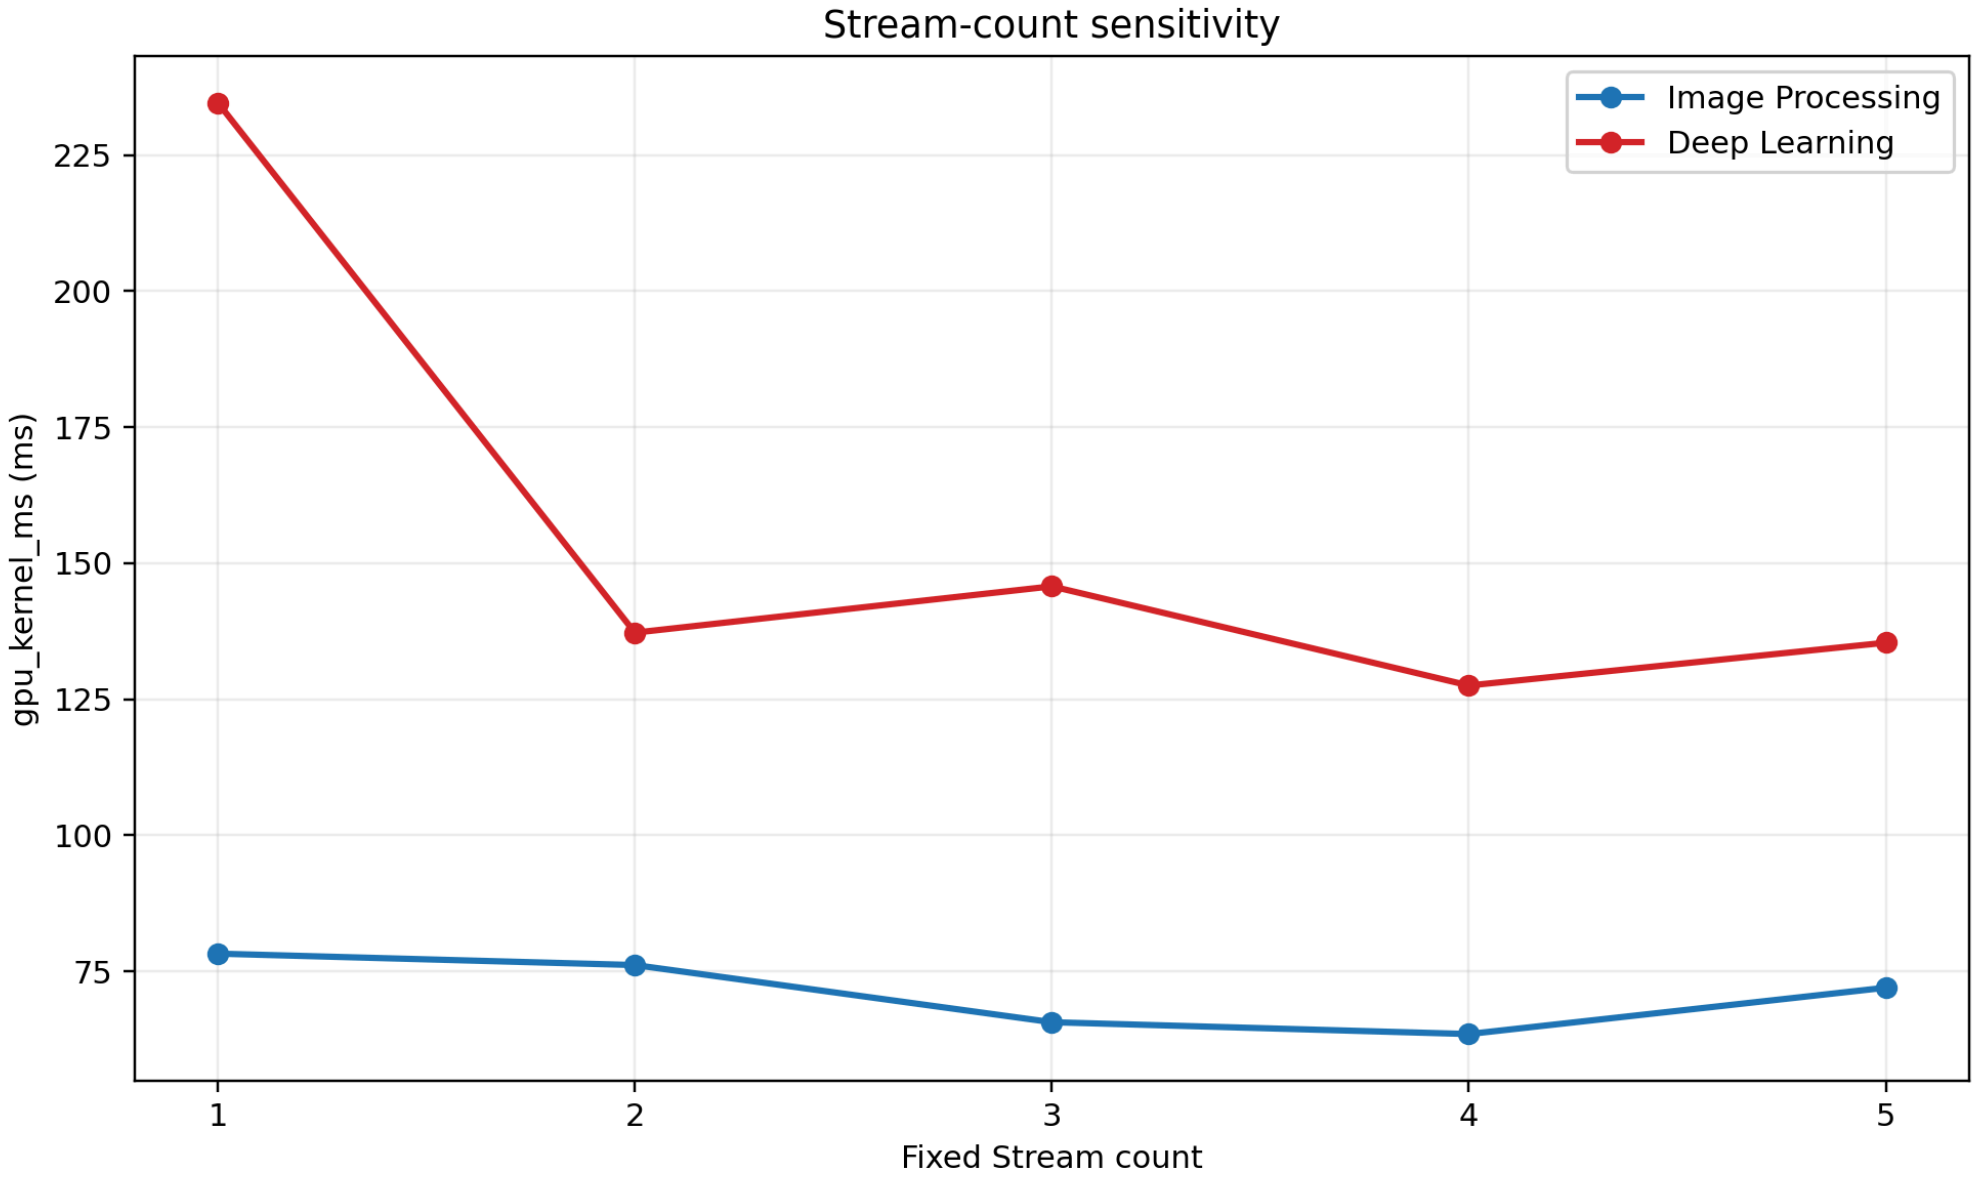
27. アブレーションから分かること

1. `No Stream placement`は全ベンチマークで遅くなった
2. `No importance`はFullより改善する場合と悪化する場合がある
3. `No SM allocation`はVector Square、Machine Learning、Image Processing、Deep LearningでFullより短かった
4. 非均等SM配分は全ケースで有効とは言えない

結論：

Stream配置は主要な性能要因であり、重要度付けと非均等SM配分の効果はベンチマーク依存である。

28. Stream数感度



29. Stream数感度の数値

`gpu_kernel_ms`で測定した平均値を示す。各点は12回実行し、最初の2回をウォームアップとして除外した10サンプルの平均である。

Stream数	Image Processing	Deep Learning
1	78.23 ms	234.64 ms
2	76.13 ms	137.24 ms
3	65.63 ms	145.75 ms
4	**63.45 ms**	**127.52 ms**
5	71.97 ms	135.39 ms

30. DAG構造による差

Image Processing

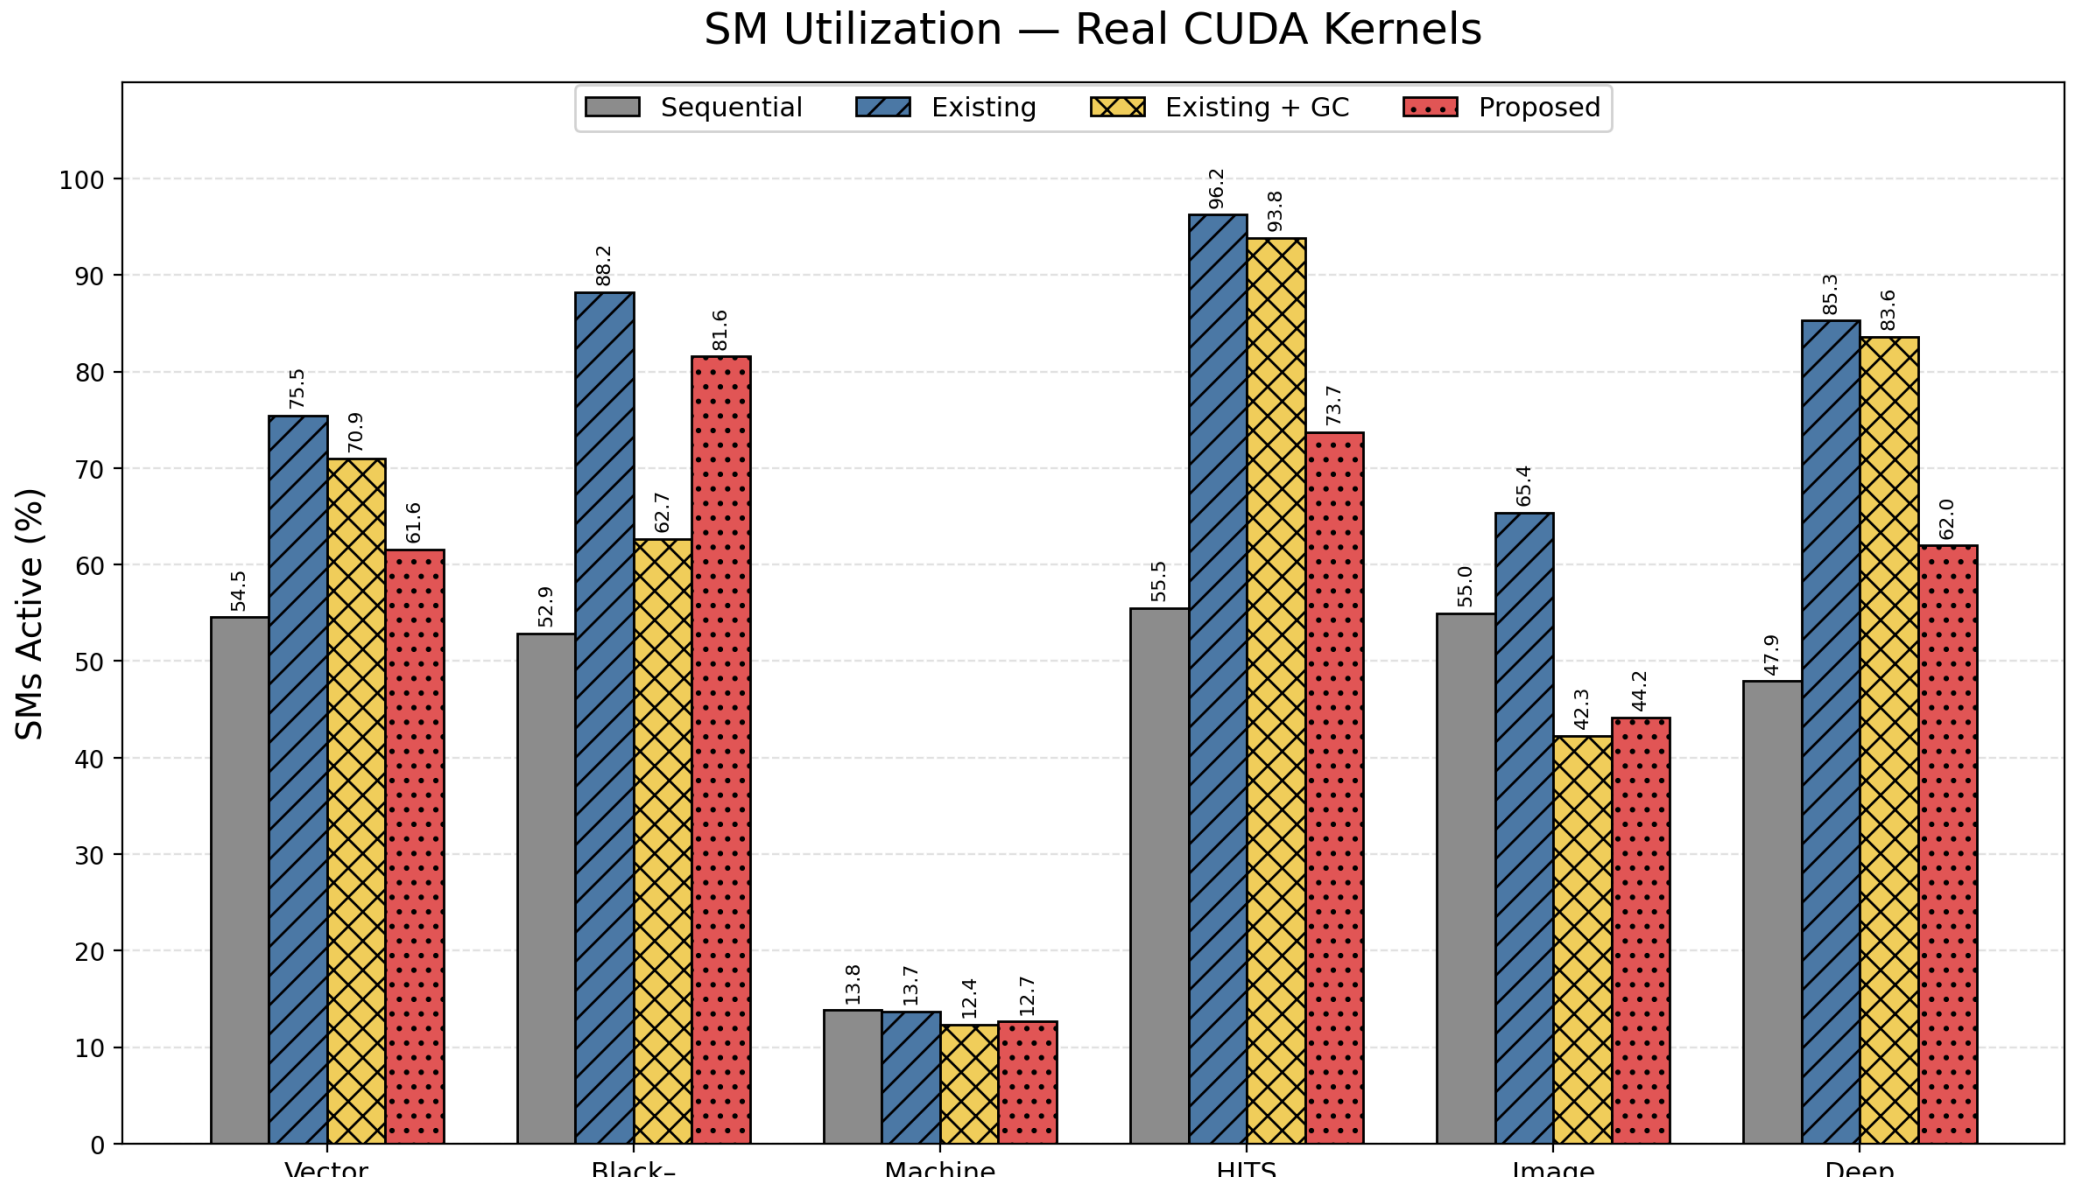
- 3つの根タスク
- 複数の分岐と合流
- 独立タスクを異なるStreamへ配置しやすい
- 複数Streamの有効範囲は、GPU Eventによる再測定後に判断する

Deep Learning

- `x`系列と`y`系列の2分岐
- 2本の長い畳み込み経路
- `concat`は両分岐の完了を待つ
- 遅い分岐が全体の完了時刻を決める

31. 実行時間とSM使用率

SM使用率は、makespanの代理指標として扱わない。



32. SM使用率：全結果

ベンチマーク	Sequential	Existing	Existing + GC	Proposed
vector_square	54.55%	**75.45%**	70.95%	61.56%
black_scholes	52.89%	**88.25%**	62.65%	81.56%
machine_learning	**13.84%**	13.70%	12.36%	12.66%
hits	42.31%	72.43%	**72.80%**	67.91%
image_processing	54.96%	**65.37%**	42.28%	44.15%
deep_learning	47.92%	**85.30%**	83.62%	61.97%

SM使用率が高い方式が、必ずしも最短時間になるわけではない。

赤字：各アプリケーションでSM使用率が最大の方式。最大化と最短時間は一致しない。

33. スケジューリングオーバーヘッド

スケジューリング計算時間とGPU実行時間を分離して測定した。

アプリ	スケジューリング	GPU時間に対する割合
black_scholes	0.139 ms	6.41%
deep_learning	0.129 ms	0.10%
hits	0.210 ms	0.12%
image_processing	0.145 ms	0.22%
machine_learning	0.129 ms	0.03%
vector_square	0.120 ms	0.17%

短い処理ではオーバーヘッドが相対的に大きい。
長時間実行または繰り返し実行されるSTGでは、配置結果の再利用が有効である。

34. 研究の結論

実験から言えること

- 複数Streamは多くの実アプリケーションで有効
- 独立分岐が多いDAGではStream配置の効果が現れやすい
- 重要度とSM配分の追加効果は、DAGとカーネル特性に依存する
- 非均等SM配分は、均等配分や既存方式を常に上回らない
- 提案方式は条件付きで有効な二段階ヒューリスティックである

提案方式の位置付け

すべてのケースで既存方式を上回る方式ではない。
DAG構造と実カーネルの処理特性を入力として、候補構成を構成的に決定する方式である。

35. 限界と今後の課題

現在の実験範囲では、以下は未検証である。

- 異なるGPUでの再現性
- 異なる入力サイズでのSMモデルの妥当性
- 全サイズ・全seedでの合成STG評価
- 小規模グラフでの厳密最適解との比較
- Streamごとの実測イベントによる合流待ち分析

したがって、現時点の主張は**単一GPU・固定入力・評価対象ベンチマークの範囲内**に限定する。

36. 最終主張

依存関係を持つGPUタスクグラフに対して、

1. 実カーネルの依存関係をSTGとして表現し、
2. bottom levelでStream配置の優先順位を決め、
3. 実測したSM数別時間モデルで資源配分を探索し、
4. 実GPU上のmakespanと数値検証で評価した。

その結果、**Stream並列性は多くのケースで有効**である一方、**非均等SM配分の追加効果は限定的で、標準的に導入すべきとは言えない**ことを確認した。

よって、本研究の貢献は「常に最速なスケジューラ」ではなく、**DAG構造と実カーネル特性に応じた有効条件と限界を明らかにした、実測ベースの二段階ヒューリスティック**である。

実務的含意：
まずStream配置で並列性を引き出し、SM分割・非均等配分は、測定上の効果が確認できる場合に限定して適用する。